

Projeto Avaliativo — Data Warehouse

Nome do Grupo: DB Adventurers

Integrantes:

- Alexandre Amador Silva — RA: _____
- Anita Shu Xian Zhu — RA: 1141352423007
- Guilherme Rodrigues Veiga — RA: _____

Domínio: Energia e Sustentabilidade

Data de Entrega: 03/06/2026

Repositório: [\[link do GitHub/GitLab\]](#)

1. Resumo Executivo

Este projeto implementa um Data Warehouse para análise da evolução energética mundial, com foco em sustentabilidade, transição energética e emissões de gases de efeito estufa. O objetivo é fornecer uma base analítica capaz de apoiar a identificação de padrões de consumo energético, participação de fontes renováveis e fósseis, eficiência energética e impactos ambientais ao longo do tempo.

Para o desenvolvimento do projeto foi utilizado o dataset "Data on Energy", disponibilizado pelo projeto Our World in Data, com indicadores demográficos, econômicos, energéticos e ambientais de mais de 200 países e regiões, cobrindo o período de 1900 a 2025.

Utilizamos DuckDB para modelagem dimensional (esquema estrela com 4 dimensões SCD2) e Python/Plotly para visualizações.

Entre os principais insights obtidos: O **Brasil (0,014)** e a **França (0,006)** registram as menores intensidades de carbono por energia consumida entre as grandes economias. O consumo global de combustíveis fósseis praticamente **dobrou (alta de ~93%)** em apenas 30 anos, saltando de **553,59** na década de 1960 para **1.068,65** na década de 1990.

2. Introdução

2.1. Contexto e Motivação

O domínio de Energia e Sustentabilidade foi escolhido devido à sua criticidade global, dado que o setor sustenta o desenvolvimento econômico, mas sua dependência de combustíveis fósseis acelera as mudanças climáticas, exigindo uma transição urgente para fontes renováveis. Para apoiar essa agenda, o Data Warehouse resolve o problema de negócio de consolidar e organizar grandes volumes de dados históricos fragmentados, transformando-os em uma base consistente para analisar a evolução da matriz energética e monitorar emissões. Essa estrutura atende diretamente a *stakeholders* como órgãos governamentais, agências reguladoras, empresas do setor elétrico, investidores, pesquisadores e organizações ambientais que necessitam de informações confiáveis para tomada de decisão e planejamento estratégico.

2.2. Objetivos do Projeto

1. Modelar um DW dimensional para análise de dados energéticos globais.
2. Implementar um pipeline ETL automatizado e idempotente.

3. Analisar a evolução temporal do consumo e da geração de energia entre países e regiões.
4. Identificar tendências de crescimento das fontes renováveis
5. Gerar dashboards para apoiar a tomada de decisão baseada em dados.

2.3. Escopo

Incluído

- Modelagem OLTP e dimensional (esquema estrela).
- Implementação de pipeline ETL utilizando DuckDB.
- Análise do consumo, produção e geração de energia.
- Análise de emissões de gases de efeito estufa e intensidade de carbono.
- Desenvolvimento de consultas analíticas e dashboards interativos.
- Aplicação de dimensões do tipo Slowly Changing Dimension (SCD2).

Excluído

- Modelos de Machine Learning para previsão de demanda energética.
- Previsão de consumo futuro ou geração futura de energia.
- Integração com sistemas externos ou APIs em tempo real.
- Processamento de dados em tempo real (streaming).

3. Fonte de Dados

3.1. Dataset Utilizado

- **Nome:** Data on Energy by *Our World in Data*
- **Fonte:** <https://github.com/owid/energy-data>
- **Período:** 1900 - 2025
- **Volume:**
 - Registros: 23377 linhas
 - Países e regiões: 314
 - Período histórico: 126 anos
 - Atributos: 130 colunas
- **Formato:** CSV (1 arquivo, ~8.8 MB)

3.2. Qualidade dos Dados

- **Valores nulos:**
 - Grande parte das colunas relacionadas a fontes específicas de energia (solar, eólica, bioenergia e nuclear) apresenta valores nulos em períodos antigos devido à inexistência ou indisponibilidade dos registros históricos. → atribuído "0"
 - Registros sem identificação de país ou ano foram removidos.
- **Outliers:** Os valores considerados elevados em indicadores como consumo energético, geração elétrica, PIB e emissões foram mantidos por representarem características reais de países com grande porte econômico e energético, como China, Estados Unidos e Índia.
- **Normalização:**

- Os códigos ISO foram utilizados como identificadores oficiais dos países.
- O campo de ano foi convertido para formato numérico inteiro.
- Colunas numéricas foram convertidas para tipos adequados
- **Tratamento de Registros Inválidos**
 - Registros sem código ISO foram removidos quando representavam agregações ou entidades não comparáveis aos países.

4. Modelagem Dimensional

4.1. Arquitetura Geral

A arquitetura adotada segue o fluxo clássico de Data Warehouse, iniciando pela extração dos dados brutos do dataset. Os dados são inicialmente carregados para uma camada de Staging, onde são realizadas validações, limpeza, padronização e transformações necessárias. Em seguida, os dados são organizados em um modelo OLTP normalizado para garantir integridade referencial e facilitar os processos de ETL. Por fim, os dados são carregados para o Data Warehouse dimensional, estruturado em esquema estrela para otimizar consultas analíticas.

[CSVs] → [Staging Views] → [OLTP Normalizado] → [ETL] → [DW Estrela]

4.2. Modelo OLTP (Normalizado)

countries

- PK: iso_code
- Atributos: country, iso_code

years


- PK: year

energy_statistics

- PK: (iso_code, year)
- FK: iso_code → countries
- FK: year → years

Objetivo: Garantir integridade referencial antes de carregar o DW.

4.3. Modelo Dimensional (Estrela)



Dimensão: dim_country (SCD Type 2)

- **Surrogate Key:** country_key (INT, gerada por sequência)
- **Business Key:** iso_code (VARCHAR)
- **Atributos:** country, iso_code
- **Controle SCD2:** start_date, end_date, is_current
- **Grain:** Cada versão histórica da classificação de um país.

Dimensão: dim_date

- **Primary Key:** date_key (INT, formato YYYY)
- **Atributos:** year, decade
- **Grain:** Um ano

Dimensão: dim_energy_profile (SCD Type 2)

- **Surrogate Key:** profile_key (INT, gerada por sequência)
- **Atributos:** renewable_level, fossil_level, low_carbon_level
- **Controle SCD2:** start_date, end_date, is_current
- **Grain:** Cada versão da classificação energética de um país ao longo do tempo.

Fato: fact_energy

- **Grain:** Uma observação de um país em um determinado ano.
- **Chaves Estrangeiras:**
 - country_key → dim_country
 - date_key → dim_date
 - profile_key → dim_energy_profile
- **Medidas:**
 - population (DOUBLE)
 - gdp (DOUBLE)
 - primary_energy_consumption (DOUBLE)

- renewables_consumption (DOUBLE)
- fossil_fuel_consumption (DOUBLE)
- solar_consumption (DOUBLE)
- wind_consumption (DOUBLE)
- hydro_consumption (DOUBLE)
- electricity_generation (DOUBLE)
- electricity_demand (DOUBLE)
- greenhouse_gas_emissions (DOUBLE)
- carbon_intensity_elec (DOUBLE)
- low_carbon_share_energy (DOUBLE)
- **Contagem esperada:** 17265 linhas

4.4. Justificativa do Grain

Escolhemos o grain de país por ano (e não por região ou continente) para permitir análises detalhadas da evolução energética e ambiental ao longo do tempo. Como cada registro do dataset representa os indicadores de um país em um determinado ano, essa granularidade preserva a máxima quantidade de informação disponível e possibilita comparações temporais e geográficas.

5. Pipeline ETL

5.1. Visão Geral

1. **Staging (00_staging.sql):** Views lendo CSVs com read_csv_auto
2. **OLTP (01_oltp.sql):** Organização em um modelo relacional simplificado
3. **DW Estrutura (02_dw_model.sql):** Criação de dimensões, fato e sequências
4. **ETL Carga (03_etl_load.sql):** carregamento das dimensões e da tabela fato
5. **Analytics (04_analytics.sql):** Consultas analíticas
6. **Performance (05_perf.sql):** Tabela agregada

5.2. Implementação do SCD Type 2

O projeto utiliza Slowly Changing Dimension Type 2 (SCD2) na dimensão dim_country e na dimensão dim_energy_profile.

Cada registro possui:

- Surrogate Key
- Data de início da vigência (start_date)
- Data de término da vigência (end_date)
- Indicador de versão atual (is_current)

Quando uma alteração é identificada, a versão anterior é encerrada e uma nova versão é criada, preservando o histórico completo da dimensão.

Exemplo simplificado:

```
-- Encerrar versão atual
UPDATE dim_energy_profile
SET
    end_date = CURRENT_DATE,
    is_current = FALSE
WHERE profile_key = ?; --não especificado para evitar alterar os dados

-- Inserir nova versão
```

```

INSERT INTO dim_energy_profile
VALUES (
    NEXTVAL('seq_profile'),
    'HIGH',
    'LOW',
    'HIGH',
    CURRENT_DATE,
    NULL,
    TRUE
);

```

Durante a execução inicial do ETL não foram detectadas mudanças históricas nos atributos monitorados, portanto cada país possui apenas uma versão ativa.

5.3. Validações de Qualidade

- Conferência da quantidade de registros importados do CSV.
- Teste de integridade referencial entre fato e dimensões.
- Verificação de registros duplicados.
- Conferência da quantidade de países carregados.
- Conferência da quantidade de anos carregados.

Exemplo de log:

```

D SELECT COUNT(*) AS qtd_staging
TÀ FROM stg_energy;

```

qtd_staging int64
17265

```

D SELECT COUNT(*) AS qtd_oltp
TÀ FROM energy_statistics;

```

qtd_oltp int64
17265

```

D SELECT COUNT(*) AS qtd_dim_country
TÀ FROM dim_country;

```

qtd_dim_country int64
220

```

D SELECT COUNT(*) AS qtd_dim_date
TÀ FROM dim_date;

```

qtd_dim_date int64
126

```
D SELECT COUNT(*) AS qtd_fact_energy
TÀ FROM fact_energy;
```

qtd_fact_energy int64
17265

5.4. Idempotência

As tabelas do modelo OLTP são recriadas a cada execução utilizando comandos DROP TABLE IF EXISTS seguidos de CREATE TABLE. Dessa forma, os dados são reconstruídos integralmente a partir da camada Staging.

As dimensões que utilizam SCD Type 2 verificam a existência de versões correntes antes da inserção de novos registros, evitando duplicações indevidas.

6. Análises e Consultas

6.1. Perguntas de Negócio

1. Quais países possuem a maior participação de fontes de baixo carbono em sua matriz energética?
2. Evolução Global do Consumo de Energias Renováveis
3. Países com Maior Intensidade de Carbono
4. Países com Maior Intensidade de Carbono
5. Relação entre Consumo de Energia e Emissões

6.2. Consultas SQL Implementadas

Q1: Países com Maior Participação de Energia de Baixo Carbono

```
SELECT
  c.country as 'País',
  AVG(f.low_carbon_share_energy) AS '% Médio de Energia de Baixo Carbono'
FROM fact_energy f
JOIN dim_country c
  ON f.country_key = c.country_key
GROUP BY c.country
ORDER BY "% Médio de Energia de Baixo Carbono" DESC
LIMIT 10;
```

Resultado:

País varchar	% Médio de Energia de Baixo Carbono double
Norway	67.10168333333336
Iceland	62.202066666666674
Sweden	54.398800000000016
Switzerland	46.09253333333334
New Zealand	38.74275
Brazil	38.610216666666667
France	34.144649999999999
Slovenia	33.10417142857143
Finland	32.462700000000001
Canada	32.400916666666666

Insight: A transição energética global ainda está no meio do caminho (maioria ainda está entre 30% e 40%, poucos passam de 60%)

Q2: Evolução Global do Consumo de Energias Renováveis

```
SELECT
    d.decade as 'Década',
    SUM(f.renewables_consumption) AS 'Consumo de Energia Renovável'
FROM fact_energy f
JOIN dim_date d
    ON f.date_key = d.date_key
GROUP BY d.decade
ORDER BY d.decade;
```

Resultado:

Década int32	Consumo de Energia Renovável double
1900	NULL
1910	NULL
1920	NULL
1930	NULL
1940	NULL
1950	NULL
1960	12577.562
1970	34539.978000000005
1980	50405.757000000002
1990	67221.966000000006
2000	84725.10500000001
2010	141676.23499999996
2020	107986.776000000004

Insight: O crescimento das fontes renováveis acelerou significativamente a partir da década de 60.

Q3: Países com Maior Intensidade de Carbono

```
SELECT
    c.country as 'País',
    AVG(f.carbon_intensity_elec) AS 'Média Intensidade de Carbono'
FROM fact_energy f
JOIN dim_country c
    ON f.country_key = c.country_key
GROUP BY c.country
ORDER BY "Média Intensidade de Carbono"
DESC LIMIT 10;
```

Resultado:

País varchar	Média Intensidade de Carbono double
Turkmenistan	1306.44440000000003
Uzbekistan	1091.7784615384612
Montserrat	1000.0
Saint Helena	1000.0
Bahrain	903.94400000000001
Brunei	900.8152
Poland	873.06722222222222
Mongolia	870.1419230769231
Botswana	849.7028
Falkland Islands	833.3333333333334

Insight: Países altamente dependentes de combustíveis fósseis no geral apresentam os maiores índices de emissão por unidade de eletricidade gerada

Q4: Relação entre Consumo de Energia e Emissões


```

SELECT
  c.country as 'País',
  SUM(f.primary_energy_consumption) AS 'Consumo de Energia',
  SUM(f.greenhouse_gas_emissions) AS 'Emissão'
FROM fact_energy f
JOIN dim_country c
  ON f.country_key = c.country_key
GROUP BY c.country
ORDER BY "Consumo de Energia"
DESC LIMIT 10;

```

Resultado:

País varchar	Consumo de Energia double	Emissão double
United States	1380510.509	54672.92
China	971149.7229999999	90110.41000000002
Russia	332016.9479999999	12268.93
Japan	295984.099	14158.75
India	232087.81	22443.05
Germany	231636.93899999998	7613.859999999999
Canada	188545.40499999997	3299.34
France	153253.635	993.49
United Kingdom	146042.13099999996	3971.380000000001
Brazil	120543.237	1732.9299999999998

Insight: A Índia tem a maior intensidade de carbono por energia consumida (Emissão/Consumo = 0.096) sinalizando uma dependência crítica de combustíveis fósseis de alta emissão e tecnologia industrial menos eficiente.

Q5: Participação de Combustíveis Fósseis por Década

```

SELECT
  d.decade as 'Década',
  AVG(f.fossil_fuel_consumption) AS 'Consumo Combustíveis Fósseis'
FROM fact_energy f
JOIN dim_date d
  ON f.date_key = d.date_key
GROUP BY d.decade
ORDER BY d.decade;

```

Resultado:


Década int32	Consumo Combustíveis Fósseis double
1900	NULL
1910	NULL
1920	NULL
1930	NULL
1940	NULL
1950	NULL
1960	553.5900030303033
1970	765.613431818181
1980	917.9512774647883
1990	1068.6524151898725
2000	1317.924363291139
2010	1591.1083367088613
2020	1681.7950936708855

Insight: Apesar do crescimento das renováveis, os combustíveis fósseis continuam representando parcela significativa da matriz energética mundial.

7. Visualizações

7.1. Gráfico 1: Evolução Global do Consumo de Energia por Década


Descrição: Gráfico de linhas mostrando a evolução temporal comparativa do consumo de combustíveis fósseis contra o consumo de energias renováveis (média) ao longo das décadas.



Insight: Embora as matrizes limpas estejam crescendo em ritmo acelerado, elas ainda estão complementando a demanda global crescente, e não substituindo os combustíveis fósseis em larga escala

7.2. Gráfico 2: Top 10 Países com Maior Participação de Energia de Baixo Carbono


Descrição: Barras horizontais com os dez países com os maiores índices médios de participação de fontes de baixo carbono em suas matrizes energéticas



Insight: Nenhuma das três maiores economias e maiores consumidoras de energia do mundo (Estados Unidos, China e Índia) aparece no Top 10.

7.3. Gráfico 3: Correlação entre o Consumo de Energia, Emissões de Carbono e a Riqueza (PIB)


Descrição: O gráfico de dispersão analisa a correlação tridimensional entre o consumo de energia primária (Eixo X), as emissões de gases de efeito estufa (Eixo Y) e o Produto Interno Bruto (PIB) representado pelo diâmetro de cada marcador (dados do ano de 2022).



Insight: Enquanto os Estados Unidos demonstram maior eficiência econômica por unidade de carbono gerada, a China e a Índia apresentam vetores de crescimento verticalizados, indicando alto índice de poluição para sustentar suas demandas industriais.

7.4. Gráfico 4: Dashboard PowerBI

Descrição: Dashboard com Média de emissão de energia limpa, consumo de energias de diversas fontes por ano (gráficos) e país (mapa), TOP 3 maiores consumidores de combustível fóssil e gráfico com as principais fontes de energia consumidas no Brasil.



Insight: O consumo de energia renovável apresentou crescimento contínuo nas últimas décadas, com forte aceleração após os anos 2000. No entanto, o consumo global de combustíveis fósseis continua superior ao das demais fontes. Brasil possui matriz relativamente limpa.

8. Performance e Otimização

8.1. Tabela Agregada por Década e Perfil Energético

Criamos uma tabela fato agregada `agg_country_year`

```
CREATE TABLE agg_country_year AS

SELECT
    dc.country,
    dd.year,
    SUM(f.renewables_consumption) AS renewables_total,
    SUM(f.fossil_fuel_consumption) AS fossil_total,
    AVG(f.low_carbon_share_energy) AS avg_low_carbon

FROM fact_energy f

JOIN dim_country dc
    ON f.country_key = dc.country_key

JOIN dim_date dd
    ON f.date_key = dd.date_key

GROUP BY
    dc.country,
    dd.year;
```

8.2. Comparação de Performance

Cenário de Teste	Linhas	Tempo Resposta	Ganho
Consultando tabela Fato	17,265	0.007s	Base (1x)
Consultando tabela Agregada	17,265	0.001s	7x mais rápido

EXPLAIN fato:	EXPLAIN agregada:
TABLE_SCAN fact_energy TABLE_SCAN dim_country TABLE_SCAN dim_date HASH_JOIN HASH_JOIN HASH_GROUP_BY)	TABLE_SCAN agg_country_year

Conclusão: A consulta na tabela fato exige leitura completa da tabela, junções e agregações em tempo de execução. Já a tabela agregada realiza apenas uma varredura simples, reduzindo significativamente o custo computacional. Os resultados demonstraram uma redução de aproximadamente 85,7% no tempo de execução

9. Referências

- Kimball, R. & Ross, M. (2013). *The Data Warehouse Toolkit*. 3rd ed.

- Documentação DuckDB: <https://duckdb.org/docs/>
- Dataset World Energy Statistics: <https://github.com/owid/energy-data>

Anexos

Anexo A: Dicionário de Dados Completo

(Ver arquivo docs/dicionario_dados.md)

Anexo B: Scripts SQL

(Ver pasta scripts/)

Anexo C: Código Python de Visualização

(Ver visualizacoes/gerar_graficos.py)